

中国科学技术大学
University of Science and Technology of China

基于 YOLOv11 的火焰与烟雾检测

Ghost 模块、BiFPN 与图像增强：论文精读和复现结果

组会论文汇报

Engineering Applications of Artificial Intelligence, 2026

2026 年 10 月

Engineering Applications of Artificial Intelligence

Elsevier 工程人工智能应用方向期刊

中国科学院期刊分区（2025 升级版）
大类：计算机科学 1 区、工程技术 1 区；相关小类为 2 区。

本文状态：非开放获取
ScienceDirect 页面显示需机构访问或购买 PDF。

论文： Improving fire and smoke detection with ghost convolutions, Bidirectional Feature Pyramid Networks, and image enhancement
Dewi et al.，Vol. 178, Part 2, Article 115116，2026-08-15
DOI:
`https://doi.org/10.1016/j.engappai.2026.115116`

这篇论文的定位

- 任务：RGB 图像中的 Fire + Smoke 双类别检测
- 基础模型：YOLOv11s
- 重点：低对比烟雾、多尺度特征和计算效率
- 论文报告：CLAHE+CS 与改进模型组合达到 89.50% mAP

分区信息为 2025 版期刊级分区，引用时以学校图书馆数据库为准。

ScienceDirect 论文页；科研通《中科院期刊分区》2025 升级版，查询于 2026-10-24

背景：监控画面中，烟雾可能先于清楚的火焰出现



测试集烟雾样例：模型预测框

- 野火监测要尽早发现火情；卫星监测覆盖和响应速度有局限。
- 远处火焰可能很小，烟羽则范围大、边界淡，两个目标的外观差异明显。
- RGB 相机便于连续观察，但云雾、天空和光照变化会让淡烟难辨。

论文关注：让模型在复杂、低对比画面中更稳地识别火焰与烟雾。

Dewi et al. (2026)，Abstract、§1；测试集样例由本次 best.pt 推理

检测难点：看得见、分得清、算得动

难点	画面里是什么情况	论文对应的处理
淡烟低对比	烟雾与天空、云雾的颜色和纹理接近，容易漏掉或误检	CLAHE + Contrast Stretching 拉开局部亮度差
尺度变化	烟羽可很小，火焰也可能只占少量像素	P4 层的 BiFPN 融合多层特征
计算开销	多分支、多尺度结构会增加推理成本	Ghost 模块以较少计算生成特征

需要分清

这些模块是针对问题的设计思路；论文结果说明组合模型有效，不等于每类困难都已被单独证明解决。

Dewi et al. (2026)，Abstract、Highlights、§2

论文方案：图像先增强，检测网络再融合特征

1. 输入 RGB 图像
2. 用 CLAHE 与 Contrast Stretching 增强对比度
3. YOLOv11s 主干和颈部加入 Ghost 模块
4. 在 P4 特征层接入 BiFPN，融合不同尺度的信息
5. 输出 Fire / Smoke 的框、类别与置信度



测试集火焰与烟雾同框样例 输出 Fire / Smoke 的框、类别和置信度。

Dewi et al. (2026)，Highlights、§2；示例为本次模型测试集输出

Ghost 模块：少做重复计算，保留有用特征

普通卷积

对输入做卷积，直接计算多张输出特征图，成本较高。

Ghost 思路

先算一部分主要特征，再用较轻的变换补出相关特征，减少重复的完整卷积。

论文放置位置

Backbone 与 Neck 中均引入 Ghost 模块，构成 YOLOv11s-GN。

用人话理解

有些特征图彼此很像。Ghost 先算代表性的那部分，再用便宜的操作补齐，目标是省计算量。

它不负责什么?

Ghost 不直接判断是不是烟；它改变的是网络提取特征的计算方式。

Dewi et al. (2026)，Highlights、§2.1；GhostNet 原理见论文参考文献

BiFPN：把不同分辨率的线索合起来



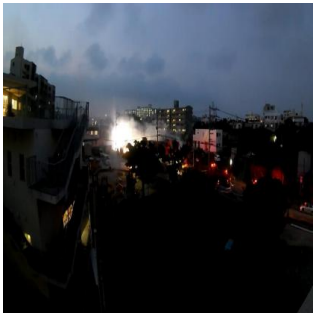
测试集小目标火焰样例

- P3 保留较细的空间位置，适合看小目标。
- P4、P5 网格更粗，能带入更大范围的语义信息。
- BiFPN 让特征沿自上而下和自下而上的路径传递，再进行加权融合。
- 论文把 BiFPN 放在 P4 阶段，目标是兼顾不同尺度的火与烟。

通俗理解：既看局部细节，也参考周围和更大范围的场景。

Dewi et al.（2026），§2.2；结构连接见本项目模型 YAML

CLAHE + CS：增强暗淡、接近背景的线索



原始测试图像



本次采用 CLAHE + CS 后的输入

CLAHE 提高局部对比度，CS 拉开强度范围。论文还比较 HE、DGC 等方法，报告 CLAHE+CS 组合效果最好（89.50% mAP）。
右图为本项目实现；公开信息不足以核实作者的全部增强参数。

Dewi et al.（2026），§2.3；右图为本项目预处理结果

数据集：Fire and Smoke Dataset

固定划分	图像数
Train	8,494
Validation	2,114
Test	1,059
合计	11,667

- RGB 图像；类别是 Smoke 和 Fire。
- 沿用数据集给出的 train / valid / test 划分。
- 本次只用 train 训练、valid 观察过程，最后在 test 报告结果。



测试集中的烟雾场景 一张图可有多个框，也可能同时包含火和烟。

Dewi et al. (2026)，§3.1；数据源：vinchole/zzzccc

复现设置：按你的要求从随机初始化训练

项目	本次设置	备注
初始化	`pretrained=False`	没有加载预训练权重
输入尺寸	640×640	与 YOLO 常用设置一致
训练轮数 / batch	300 / 40	RTX 5090，GPU 3
优化器	SGD，初始学习率 0.01	seed 42
训练数据	CLAHE + CS 版本	保留官方固定划分
完成时间	约 3 小时 29 分钟	单次训练

复现差异

本次从零初始化；作者 Notebook 使用预训练权重，且公开实现中部分结构细节无法独立核验。因此结果是独立复现参考。

训练参数见本项目脚本；差异依据作者仓库 README 与 Notebook

配置文件各管一件事

模型 YAML

`yolo11s_gn_bifpn.yaml`

说明网络每一层接谁、使用什么模块、检测头读取哪些尺度。

数据 YAML

`data_clahe_cs.yaml`

指向 train / valid / test 文件夹，并写明类别顺序：Smoke、Fire。

训练脚本

`train.py`

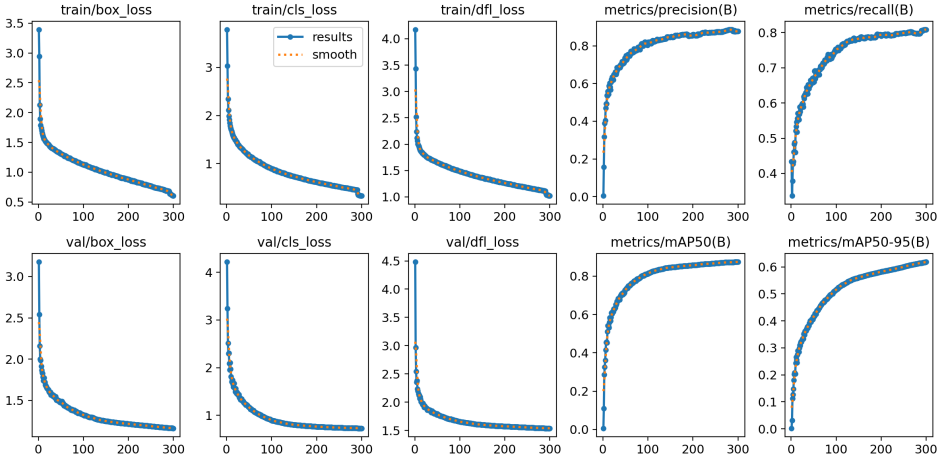
指定 batch、轮数、优化器、GPU，以及 `pretrained=False`。

一句话

模型 YAML 决定“网络长什么样”，数据 YAML 决定“读哪些图和标签”，训练脚本决定“怎么学”。

本项目配置文件；模型模块实现见 `models/ghost_bifpn.py`

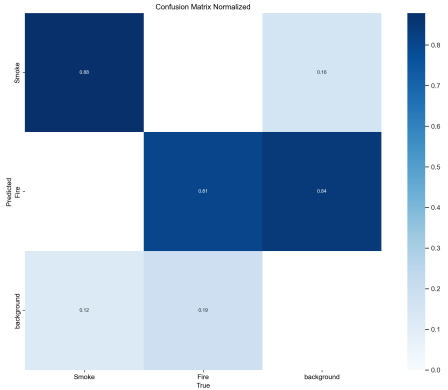
训练曲线：loss 持续下降，验证 mAP 稳步上升



300 个 epoch 的训练记录；曲线来自本次 batch 40、从零初始化的完整训练。

本次 300 epoch 训练曲线，服务器 results.png

验证集诊断：漏检与背景误报都要看



这是训练过程中的验证集归一化混淆矩阵，不是独立测试集指标。

- Smoke 约 88% 落在正确类别；Fire 约 81%。
- 背景误报里，约 84% 的未匹配预测属于 Fire 类。
- 背景误报会影响监控场景的实际告警负担。

训练验证集；best.pt

独立测试集结果：Smoke 好于 Fire

类别	Precision	Recall	AP@0.5	AP@0.5:0.95
Smoke	0.899	0.838	0.894	0.684
Fire	0.835	0.746	0.830	0.531
总体	0.867	0.792	0.862	0.608

测试集：1,059 张图、3,162 个标注框。

结论怎么读

- **mAP@0.5 = 86.2%：在较宽松的框重合标准下，整体检测较好。**
- **mAP@0.5:0.95 = 60.8%：严格定位标准下还有改进空间。**
- **Smoke AP 高于 Fire 6.4 个百分点；小火和复杂背景值得继续查错。**

best.pt 在固定 test split 上验证

测试图像上的实际预测



烟雾 + 火焰



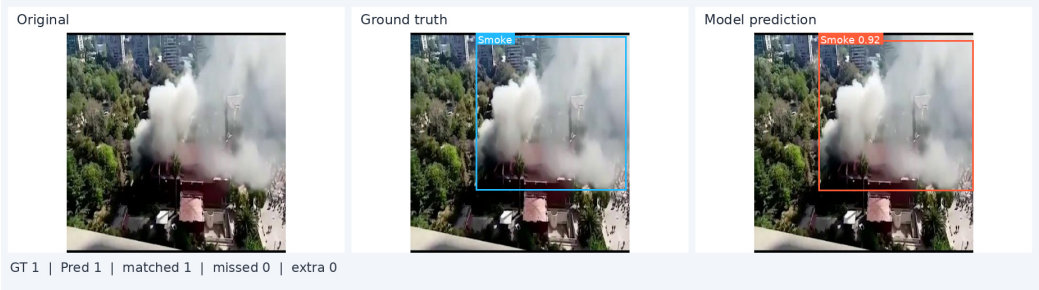
烟雾



火焰

best.pt 在独立测试图像上给出火与烟的框和置信度；总体效果以整套测试指标为准。

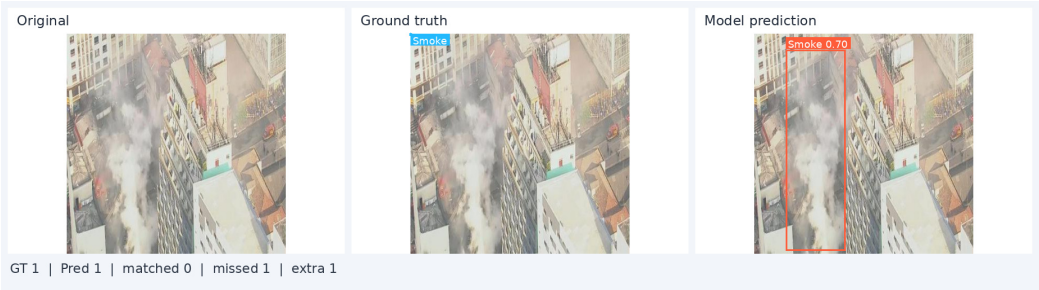
固定 test split 样例；置信度阈值 0.25



烟雾：标注 1 框、预测 1 框；IoU 0.949，置信度 0.921。

蓝/紫框为标注，红框为预测；输入为 CLAHE+CS 图；固定测试集样例

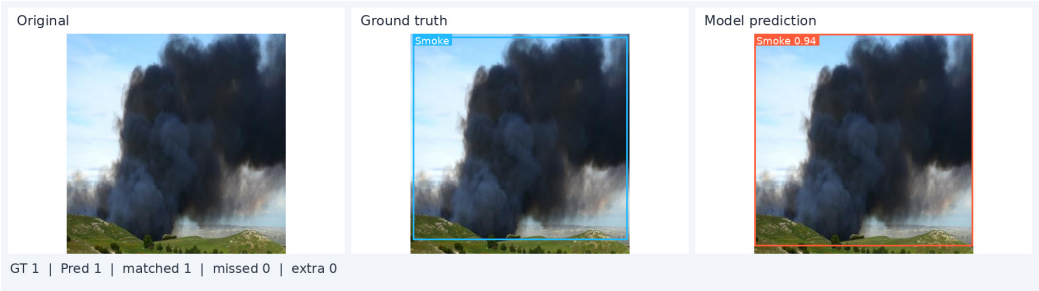
复现图像 2/8：烟雾边缘带来框位置偏差



标注与预测各 1 框，但同类别框的 IoU 未达到 0.5。

模型输入为 CLAHE+CS 图；预测框叠加在原图；固定测试集样例

复现图像 3/8：烟雾检测与标注接近



烟雾：标注 1 框、预测 1 框；IoU 0.936，置信度 0.944。

蓝/紫框为标注，红框为预测；固定测试集样例

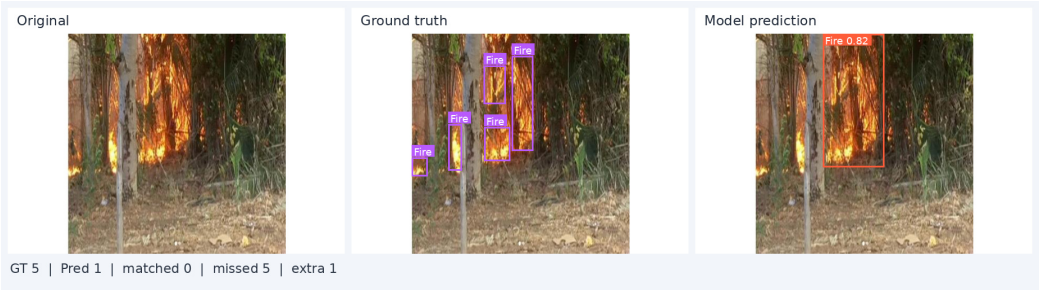
复现图像 4/8：单个火焰定位较准



火焰：标注 1 框、预测 1 框；IoU 0.961，置信度 0.911。

蓝/紫框为标注，红框为预测；固定测试集样例

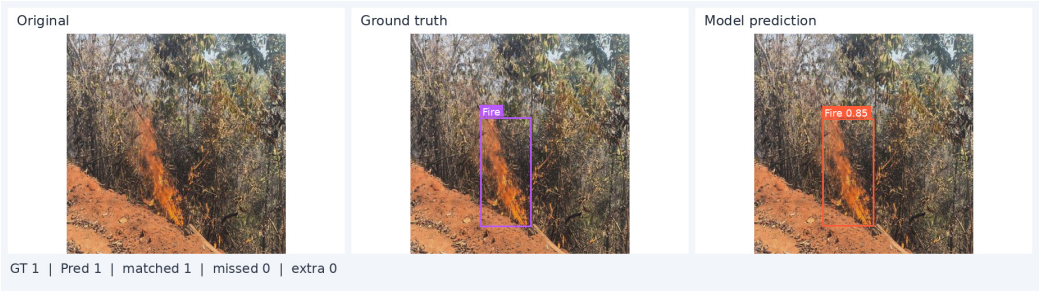
复现图像 5/8：相邻火焰容易被合并



标注 5 个火焰框，模型输出 1 个较大的框；按 IoU 0.5 标准均未匹配。

模型能指出火焰区域，但框的拆分和定位仍有误差；固定测试集样例

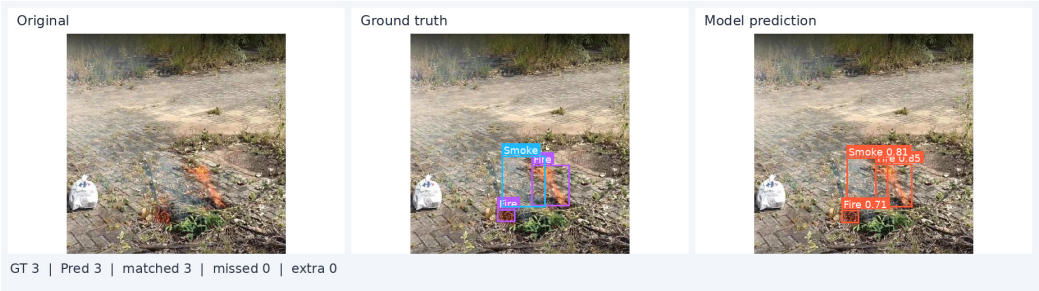
复现图像 6/8：单个火焰框匹配



火焰：标注 1 框、预测 1 框；IoU 0.943，置信度 0.848。

蓝/紫框为标注，红框为预测；固定测试集样例

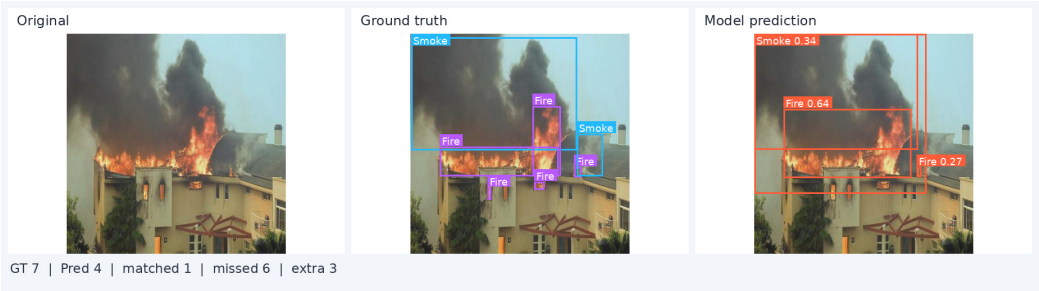
复现图像 7/8：火焰与烟雾同时检出



火烟同框：3 个标注框与 3 个预测框均满足同类别、IoU ≥ 0.5。

蓝/紫框为标注，红框为预测；固定测试集样例

复现图像 8/8：火烟混杂的困难样例



标注 7 框、预测 4 框；同类别且 IoU ≥ 0.5 的匹配 1 框，另有 6 个标注框未匹配。

这些是定性例图，不代表测试集平均表现；存在框位置与标注差异

所以，这次训练有效果吗？

可以确认的

- 完成 300 轮训练，loss 收敛。
- 独立测试集总体 mAP@0.5 为 86.2%。
- 火焰、烟雾都能检出，测试图上可看到对应框。

结论：有实际检测效果，可作为后续实验的起点。

还不能下的结论

- 论文摘要报告 89.50% mAP；公开页面未在该数值旁标明与本次相同的 mAP 阈值。
- 本次从零初始化，代码结构和增强细节也有实现选择。
- 单次训练、单一数据集，不能证明复杂野外场景都可靠。

有检测效果；但不能据此说已严格复现论文或达到部署要求

论文报告值见 ScienceDirect Highlights；本次指标见固定测试集评估

局限与可以继续做的方向

当前局限

- 烟雾边界模糊，框的精确位置仍不稳定。
- 当前只在一个公开数据集上评估，没按云雾、逆光、夜间拆分误报率。
- 只有一次随机种子；尚未做逐模块消融。

后续研究思路

1. 用同一训练协议比较从零训练与预训练初始化。
2. 加入视频连续帧信息，过滤短暂烟尘和光照误报。
3. 对烟雾尝试分割或边界不确定性建模，不只回归矩形框。
4. 跨数据集测试，按白天/夜间、云雾、逆光分别统计结果。

可借鉴的核心思路

先定位真实困难，再分别从输入图像、特征提取和多尺度融合入手；用分场景评估验证每个改动是否真有帮助。

基于论文方法与本次复现局限提出的后续方向

1. C. Dewi, D. Thiruvady, S. A. Philemon, N. Zaidi. “Improving fire and smoke detection with ghost convolutions, Bidirectional Feature Pyramid Networks, and image enhancement.” *Engineering Applications of Artificial Intelligence*, 178 (2026), 115116. DOI: `https://doi.org/10.1016/j.engappai.2026.115116`.
2. 官方代码仓库：`https://github.com/ChristineDewi/YOLO_GN`
3. Fire and Smoke Dataset：`https://github.com/vinchole/zzzccc`
4. 期刊分区：科研通，Engineering Applications of Artificial Intelligence，2025 年中科院升级版分区页面。
5. 复现记录、模型 YAML、训练脚本与测试结果：本项目 `README.md`、`复现进度.md`、`models/`、`scripts/`。

谢谢